

DAPO: 大规模开源LLM强化学习系统

¹ByteDance Seed ²Institute for AI Industry Research (AIR), Tsinghua University

³The University of Hong Kong

⁴SIA-Lab of Tsinghua AIR and ByteDance Seed

Full author list in Contributions

Abstract

推理扩展赋予LLM前所未有的推理能力，强化学习是引发复杂推理的核心技术。然而，最先进的推理LLM的关键技术细节是隐藏的（例如在OpenAI o1博客和DeepSeek R1技术报告中），因此社区仍然难以重现他们的RL训练结果。我们提出了解耦剪辑和动态采样策略优化（**DAPO**）算法，并完全开源了一个最先进的大规模RL系统，该系统使用Qwen2.5-32B基础模型在AIME 2024上实现了50个点。与之前隐瞒训练细节的工作不同，我们介绍了我们算法的四项关键技术，这些技术使大规模LLM RL取得了成功。此外，我们开源了基于**verl**框架的培训代码^a，以及精心策划和处理的数据集。我们开源系统的这些组件增强了可重复性，并支持大规模LLM RL的未来研究。

Date: March 17, 2025

Correspondence: Qiyang Yu at yuqy22@mails.tsinghua.edu.cn

Project Page: <https://dapo-sia.github.io/>

^a<https://github.com/volcengine/verl>




Figure 1 AIME 2024在Qwen2.5-32B基础模型上的**DAPO**得分为**DAPO**，使用50%的训练步长，优于之前的SoTA DeepSeek-R1-Zero-Qwen-32B。

1 介绍

OpenAI的o1[1]和DeepSeek的R1[2]等测试时间扩展为大型语言模型（LLM）[3–7]带来了深刻的范式转变。测试时间缩放可以实现更长的思维链，并诱导复杂的推理行为，这使得模型在竞争性数学和编码任务（如AIME和Codeforce）中具有优势。

推动这场革命的核心技术是大规模强化学习（RL），它引发了复杂的推理行为，如自我验证和迭代细化。然而，可扩展RL训练的实际算法和关键配方仍然是一个神话，隐藏在现有推理模型[1, 2, 8–11]的技术报告中。本文揭示了大规模强化学习训练中的重大障碍，并开源了一个可扩展的强化学习系统，该系统具有完全开源的算法、训练代码和数据集，可提供具有行业级强化学习结果的民主化解决方案。

我们在Qwen2.5-32B[12]上进行了实验，作为RL的预训练模型。在我们最初的GRPO运行中，我们在AIME上只获得了30分，远低于DeepSeek的RL（47分）。彻底的分析表明，朴素的GRPO基线存在几个关键问题，如熵崩溃、奖励噪声和训练不稳定。更广泛的社区在复制DeepSeek的结果[13–19]时遇到了类似的挑战，这表明R1论文中可能遗漏了开发行业级、大规模和可复制的RL系统所需的关键培训细节。

为了缩小这一差距，我们发布了一个用于大规模LLM RL的开源最先进系统，该系统基于Qwen2.5-32B模型在AIME 2024上获得了50分，超过了DeepSeek-R1-Zero-Qwen-32B[2]使用50%训练步骤获得的先前最先进结果（47分）（图1）。我们提出了解耦剪辑和动态采样策略优化（**DAPO**）算法，并介绍了4项关键技术，使RL在长CoT RL场景中大放异彩。详细信息见第3节。

1. **Clip Higher**，促进系统的多样性，避免熵崩溃；
2. 动态采样，提高训练效率和稳定性；
3. 令牌级策略梯度损失，这在长CoT RL场景中至关重要；
4. 超长奖励整形，减少奖励噪音，稳定训练。

我们的实现基于verl[20]。通过全面发布我们最先进的强化学习系统，包括训练代码和数据，我们的目标是为大型LLM强化学习提供有价值的见解，造福更大的社区。

2 预备性的

2.1 近端策略优化（PPO）

PPO[21]引入了一个用于策略优化的截断代理目标。通过使用clip将策略更新限制在先前策略的近端区域内，PPO稳定了训练并提高了样本效率。具体而言，PPO通过最大化以下目标来更新政策：

$$\mathcal{J}_{\text{PPO}}(\theta) = \mathbb{E}_{(q,a) \sim \mathcal{D}, o_{\leq t} \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\min \left(\frac{\pi_{\theta}(o_t | q, o_{\leq t})}{\pi_{\theta_{\text{old}}}(o_t | q, o_{\leq t})} \hat{A}_t, \text{clip} \left(\frac{\pi_{\theta}(o_t | q, o_{\leq t})}{\pi_{\theta_{\text{old}}}(o_t | q, o_{\leq t})}, 1 - \varepsilon, 1 + \varepsilon \right) \hat{A}_t \right) \right], \quad (1)$$

其中 (q, a) 是来自数据分布 $\mathcal{D}$ 的问答对， ε 是重要性采样率的限幅范围，是时间步 t 长优势的估计器。给定价值函数 V 和奖励函数 R ， $\hat{A}_t$ 使用广义优势估计（GAE）[22]计算：

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}, \quad (2)$$

哪里

$$\delta_l = R_l + \gamma V(s_{l+1}) - V(s_l), \quad 0 \leq \gamma, \lambda \leq 1. \quad (3)$$

2.2 组相对策略优化（GRPO）

与PPO相比，GRPO消除了价值函数，并以组相对的方式估计优势。对于特定的问答对，行为策略 $\pi_{\theta_{\text{old}}}$ 会对一组单独的 G 个回答 $\{o_i\}_{i=1}^G$ 进行采样。然后，通过归一化组级奖励 $\{R_i\}_{i=1}^G$ 来计算第 i -个 i 响应的优势：

$$\hat{A}_{i,t} = \frac{r_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}. \quad (4)$$




Figure 2 在应用Clip Higher策略之前和之后，AIME测试集的准确性和RL训练过程中参与者模型生成概率的熵。

与PPO类似，GRPO采用了一个限制目标，以及直接施加的KL惩罚条款：

$$\mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip} \left(r_{i,t}(\theta), 1 - \varepsilon, 1 + \varepsilon \right) \hat{A}_{i,t} \right) - \beta D_{\text{KL}}(\pi_{\theta} || \pi_{\text{ref}}) \right) \right], \quad (5)$$

哪里

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} | q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} | q, o_{i,<t})}. \quad (6)$$

同样值得注意的是，GRPO在样本级别计算目标。确切地说，GRPO首先计算每个生成序列中的平均损失，然后对不同样本的损失进行平均。正如我们将在第3.3节中讨论的那样，这种差异可能会对算法的性能产生影响。

2.3 消除KL发散

KL惩罚条款用于规范在线政策和冻结参考政策之间的差异。在RLHF场景[23]中，RL的目标是在不偏离初始模型太远的情况下调整模型行为。然而，在训练长CoT推理模型的过程中，模型分布可能会与初始模型明显偏离，因此这种限制是不必要的。因此，我们将从我们提出的算法中排除KL项。

2.4 基于规则的奖励建模

使用奖励模型通常会遇到奖励黑客问题[24–29]。相反，我们直接使用可验证任务的最终准确性作为结果奖励，使用以下规则计算：

$$R(\hat{y}, y) = \begin{cases} 1, & \text{is_equivalent}(\hat{y}, y) \\ -1, & \text{otherwise} \end{cases} \quad (7)$$

其中 y 是地面真实答案， $\hat{y}$ 是预测答案。这被证明是激活基础模型推理能力的有效方法，如自动定理证明[30–33]、计算机编程[34–37]和数学竞赛[2]等多个领域所示。

3 DAPO

我们提出了解耦剪辑和动态采样策略优化 (DAPO) 算法。DAPO对每个与答案 a 配对的问题 q 的一组输出 $\{o_i\}_{i=1}^G$ 进行采样, 并通过以下目标优化策略:

$$\begin{aligned} \mathcal{J}_{\text{DAPO}}(\theta) = & \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \\ & \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip} \left(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}} \right) \hat{A}_{i,t} \right) \right] \\ \text{s.t. } & 0 < \left| \{o_i \mid \text{is_equivalent}(a, o_i)\} \right| < G, \end{aligned} \quad (8)$$

哪里

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}, \quad \hat{A}_{i,t} = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}. \quad (9)$$

完整的算法可以在算法1中找到。在本节中, 我们将介绍与DAPO相关的关键技术。

3.1 抬高天花板: 夹得更高

在我们使用初始PPO[21]或GRPO[38]的初步实验中, 我们观察到了熵崩溃现象: 随着训练的进行, 策略的熵迅速降低 (Figure 2b)。某些群体的抽样反应往往几乎相同。这表明有限的探索和早期的确定性政策, 这可能会阻碍扩展过程。

我们提出了**Clip Higher**策略来解决这个问题。在剪切近邻策略优化 (PPO-Clip) [21]中引入了对重要采样率的剪切, 以限制信任区域并提高RL的稳定性。我们发现上剪切可以限制策略的探索。在这种情况下, 使“开发代币”更有可能比提高不太可能的“探索代币”的可能性要容易得多。

具体来说, 当 $\varepsilon = 0.2$ (大多数算法的默认值) 时, 考虑两个具有概率 $\pi_{\theta_{\text{old}}}(o_i \mid q) = 0.01$ 和 0.9 的动作。最大可能的更新概率 $\pi_{\theta}(o_i \mid q)$ 分别为 0.012 和 1.08 。这意味着, 对于概率较高 (*e.g.* 0.9) 的令牌, 约束较小。相反, 对于低概率令牌, 实现概率的非平凡增加要困难得多。根据经验, 我们还观察到剪切令牌的最大概率大约 $\pi_{\theta}(o_i \mid q) < 0.2$ 为 (Figure 3a)。这一发现支持了我们的分析, 即上限削波阈值确实限制了低概率令牌的概率增加, 从而可能限制了系统的多样性。

遵循**Clip Higher**策略, 我们将较低和较高的剪裁范围解耦为 $\varepsilon_{\text{high}}$, 如 ε_{low} 方程式10所示:

$$\begin{aligned} \mathcal{J}_{\text{DAPO}}(\theta) = & \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \\ & \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip} \left(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}} \right) \hat{A}_{i,t} \right) \right] \\ \text{s.t. } & 0 < \left| \{o_i \mid \text{is_equivalent}(a, o_i)\} \right| < G. \end{aligned} \quad (10)$$

我们增加的 $\varepsilon_{\text{high}}$ 值为低概率令牌的 $\varepsilon_{\text{high}}$ 增加留出了更多空间。如所Figure 2示, 这种调整有效地增强了策略的熵, 并促进了更多样化样本的生成。我们选择保持 ε_{low} 相对较小的值, 因为增加它会抑制这些令牌的概率, 从而导致采样空间的崩溃。

3.2 越快乐: 动态采样

当某些提示的精度等于1时, 现有的RL算法存在梯度下降问题。例如, 对于GRPO, 如果特定提示的所有输出 $\{o_i\}_{i=1}^G$ 都是正确的, 并且获得了相同的奖励1, 则该组的最终优势为零。零优势导致策略更新没有梯度, 从而降低了采样效率。根据经验, 精度等于1的样本数量继续增加, 如所示。这意味着每批中的有效提示数量不断减少, 这可能会导致梯度的较大方差, 并抑制模型训练的梯度信号。

为此, 我们建议对提示进行过采样和过滤, 精度等于方程式11中所示的**1**和**0**, 使批次中的所有提示都具有有效的梯度, 并保持一致的提示数量。在训练之前, 我们会一直采样, 直到批次中充满准确度既不是0也不是1的样本。




Figure 3 参与者模型概率分布的熵，以及响应长度的变化。

$$\begin{aligned}
 \mathcal{J}_{\text{DAPO}}(\theta) = & \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \\
 & \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip} \left(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}} \right) \hat{A}_{i,t} \right) \right] \\
 \text{s.t. } & 0 < \left| \{o_i \mid \text{is_equivalent}(a, o_i)\} \right| < G.
 \end{aligned} \tag{11}$$

请注意，这种策略不一定会阻碍训练效率，因为如果RL系统是同步的，并且生成阶段不是流水线的，则生成时间通常由长尾样本的生成决定。此外，我们发现，通过动态采样，实验更快地达到了相同的性能，如图所示。

3.3 再平衡法案：代币级策略梯度损失


原始的GRPO算法采用样本级损失计算，首先按每个样本内的令牌对损失进行平均，然后汇总各个样本的损失。在这种方法中，在最终损失计算中为每个样本分配相等的权重。然而，我们发现这种减少损耗的方法在长CoT RL场景中引入了几个挑战。

由于在损失计算中为所有样本分配了相同的权重，因此较长响应中的令牌（包含更多令牌）可能对整体损失的贡献不成比例地低，这可能会导致两种不利影响。首先，对于高质量的长样本，这种效应可能会阻碍模型在其中学习推理相关模式的能力。其次，我们观察到过长的样本往往表现出低质量的模式，如胡言乱语和重复单词。因此，由于样本级损失计算无法有效惩罚长样本中的这些不希望的模式，导致熵和响应长度的不健康增加，如和Figure 4b所示。


我们在长CoT RL场景中引入了令牌级策略梯度损失，以解决上述局限性：

$$\begin{aligned}
 \mathcal{J}_{\text{DAPO}}(\theta) = & \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \\
 & \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip} \left(r_{i,t}(\theta), 1 - \varepsilon_{\text{low}}, 1 + \varepsilon_{\text{high}} \right) \hat{A}_{i,t} \right) \right], \\
 \text{s.t. } & 0 < \left| \{o_i \mid \text{is_equivalent}(a, o_i)\} \right| < G.
 \end{aligned} \tag{12}$$

在这种设置下，与较短的序列相比，较长的序列对整体梯度更新的影响更大。此外，从单个令牌的角度来看，如果特定的生成模式会导致奖励的增加或减少，那么无论它出现的响应时间长短，它都会被同等地提示或抑制。




(a) 行动者模型生成概率的熵。




(b) 参与者模型生成的响应的平均长度

Figure 4 参与者模型概率分布的熵，以及响应长度的变化。



(a) AIME上的表现。



(b) 演员模型的熵。

Figure 5 在应用超长奖励整形策略之前和之后，AIME上行动者模型的准确性及其生成概率的熵。

3.4 捉迷藏：俯视奖励塑造

在RL训练中，我们通常会设置生成的最大长度，并相应地截断过长的样本。我们发现，截断样本的奖励整形不当会引入奖励噪声，并显著扰乱训练过程。

默认情况下，我们为截断的样本分配惩罚性奖励。这种方法可能会在训练过程中引入噪声，因为健全的推理过程可能仅因其过长而受到惩罚。这种惩罚可能会使模型在推理过程的有效性方面产生混淆。

为了研究这种奖励噪声的影响，我们首先应用了一种超长滤波策略，该策略掩盖了截断样本的损失。我们发现，这种方法显著稳定了训练并提高了表现，如所Figure 5示。

此外，我们提出了软超长惩罚（方程13），这是一种长度感知惩罚机制，旨在塑造截断样本的奖励。具体来说，当响应长度超过预定义的最大值时，我们定义一个惩罚间隔。在这个时间间隔内，反应时间越长，受到的惩罚就越大。该惩罚被添加到原始的基于规则的正确性奖励中，从而向模型发出信号以避免过长的响应。

$$R_{\text{length}}(y) = \begin{cases} 0, & |y| \leq L_{\max} - L_{\text{cache}} \\ \frac{(L_{\max} - L_{\text{cache}}) - |y|}{L_{\text{cache}}}, & L_{\max} - L_{\text{cache}} < |y| \leq L_{\max} \\ -1, & L_{\max} < |y| \end{cases} \quad (13)$$

Algorithm 1 DAPO: Decoupled Clip and Dynamic sAmpling Policy Optimization

Input initial policy model π_θ ; reawrd model R ; task prompts $\mathcal{D}$; hyperparameters $\epsilon_{\text{low}}, \epsilon_{\text{high}}$

```
1: for step = 1,...,M do
2:   Sample a batch  $\mathcal{D}_b$  from  $\mathcal{D}$ 
3:   Update the old policy model  $\pi_{\theta_{\text{old}}} \leftarrow \pi_\theta$ 
4:   Sample  $G$  outputs  $\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)$  for each question  $q \in \mathcal{D}_b$ 
5:   Compute rewards  $\{r_i\}_{i=1}^G$  for each sampled output  $o_i$  by running  $R$ 
6:   Filter out  $o_i$  and add the remaining to the dynamic sampling buffer (Dynamic Sampling Equation (11))
7:   if buffer size  $n_b < N$ :
8:     continue
9:   For each  $o_i$  in the buffer, compute  $\hat{A}_{i,t}$  for the  $t$ -th token of  $o_i$  (Equation (9))
10:  for iteration = 1, ...,  $\mu$  do
11:    Update the policy model  $\pi_\theta$  by maximizing the DAPO objective (Equation (8))
```

Output π_θ

3.5 数据集转换

我们的数据集来源于AoPS¹通过网页抓取和手动注释相结合的方式，将网站和官方比赛主页连接起来。数学数据集的答案通常有各种格式，如表达式、公式和数字，这使得设计全面的规则来解析它们变得具有挑战性。为了使用规则提供准确的奖励信号，并尽量减少公式解析器引入的错误，受AIME的启发，我们选择答案并将其转换为易于解析的整数。例如，如果原始答案以的 $\frac{a+\sqrt{b}}{c}$ 形式表示，我们指示LLM修改问题，使预期的答案变为 $a + b + c$ 。经过选择和转换，我们得到了**-Math-17K**数据集，它由17K个提示组成，每个提示都有一个整数作为答案。

4 实验

4.1 培训详情

在这项工作中，我们特别关注数学任务来评估我们的算法，这些任务可以很容易地转移到其他任务中。我们采用verl框架[20]进行培训。我们使用朴素GRPO[38]作为我们的基线算法，并使用组奖励归一化来估计优势。

对于超参数，我们使用具有恒定学习率的 1×10^{-6} AdamW[39]优化器，在20个部署步骤中进行线性预热。对于推出，提示批量大小为512，我们为每个提示采样16个响应。对于训练，小批量大小设置为512，即每个卷展步骤有16个梯度更新。对于超长奖励整形，我们将预期的最大长度设置为16384个令牌，并分配额外的4096个令牌作为软惩罚缓存。因此，生成令牌的最大数量设置为20480个令牌。对于**Clip Higher**机制，我们将剪裁参数 ϵ_{low} 设置为0.2和 ϵ_{high} 0.28，有效地平衡了探索和开发之间的权衡。对于AIME的评估，我们重复评估集32次并报告avg@32为了结果的稳定性。评估的推理超参数设置为温度1.0和顶部0.7。

4.2 主要成果

AIME 2024上的实验表明，**DAPO**已经成功地将Qwen-32B Base模型训练成一个强大的推理模型，其性能优于DeepSeek使用R1方法在Qwen2.5-32B上的实验。在图1中，我们观察到AIME 2024的性能有了显著提高，精度从近0%提高到50%。值得注意的是，这种改进只需要DeepSeek-R1-Zero-Qwen-32B所需训练步骤的50%即可实现。

我们分析了每种训练技术在我们的方法中的贡献，详见。观察到的改进证明了这些技术在强化学习训练中的有效性，每种技术都在AIME 2024中贡献了几个精度点。值得注意的是，考虑到普通的GRPO设置，从Qwen2.5-32B基础模型训练只能达到30%的精度。

¹<https://artofproblemsolving.com/>




Figure 6 在基线设置上应用动态采样前后的训练进度。

Table 1 应用于DAPO的渐进技术的主要结果

Model	AIME24 _{avg} @32
DeepSeek-R1-Zero-Qwen-32B	47
Naive GRPO	30
+ Overlong Filtering	36
+ Clip-Higher	38
+ Soft Overlong Punishment	41
+ Token-level Loss	42
+ Dynamic Sampling (DAPO)	50

对于令牌级别的损失，虽然它带来的性能改进较少，但我们发现它增强了训练的稳定性，使训练时间增长更健康。

在应用动态采样时，尽管由于滤除零梯度数据而需要采样更多数据，但总体训练时间不会受到显著影响。如所Figure 6示，尽管采样实例的数量增加了，但由于所需的训练步骤更少，模型的收敛时间甚至缩短了。

4.3 培训动态

大型语言模型的强化学习不仅是一个前沿的研究方向，也是一个本质上复杂的系统工程挑战，其特征是各个子系统的相互依存。对任何单个子系统的修改都可能在系统中传播，由于这些组件之间复杂的相互作用，会导致不可预见的后果。即使初始条件看似微小的变化，如数据和超参数的变化，也可以通过迭代强化学习过程放大，从而产生结果的重大偏差。这种复杂性经常使研究人员面临两难境地：即使经过细致的分析和有充分理由的预期，即修改将增强训练过程的特定方面，实际结果也经常偏离预期的轨迹。因此，在实验过程中监测关键的中间结果对于快速识别差异来源并最终完善系统至关重要。

- 生成响应的长度是一个与训练稳定性和性能密切相关的指标，如所Figure 7a示。长度的增加为模型提供了更大的探索空间，允许对更复杂的推理行为进行采样，并通过训练逐渐加强。然而，值得注意的是，在训练过程中，长度并不总是保持持续上升的趋势。在某些相当长的时期内，它可能会表现出停滞甚至下降的趋势，这也在中[2]得到了证明。我们通常使用长度和验证准确性作为评估实验是否恶化的指标。
- 训练过程中的奖励动态一直是强化学习中的关键监测指标之一，如所Figure 7b示。在我们的大多数实验中，奖励增加的趋势相对稳定，不会因实验设置的调整而大幅波动或下降。这表明，在给定可靠的奖励信号的情况下，语言模型可以稳健地拟合训练集的分布。然而，我们发现训练集上的最终奖励通常与验证集上的准确性相关性很小，这表明训练集过拟合。
- 参与者模型的熵和生成概率与模型的探索能力有关，是我们在实验中密切监控的关键指标。直观地说，




Figure 7 响应长度、奖励分数、生成熵和的DAPO平均概率的DAPO度量曲线，显示了RL训练的动态，并作为识别潜在问题的重要监测指标。

模型的熵需要保持在适当的范围内。熵过低表明概率分布过于尖锐，导致勘探能力丧失。相反，过高的熵通常与过度探索的问题有关，如胡言乱语和重复生成。对于生成概率，情况正好相反。如中Section 3.1所示，通过应用Clip Higher策略，我们有效地解决了熵崩溃的问题。在后续的实验中，我们发现保持熵的缓慢上升趋势有助于提高模型性能，如Figure 7c和Figure 7d所示。

4.4 个案分析研究

在RL训练过程中，我们观察到一个有趣的现象：参与者模型的推理模式随着时间的推移而动态演变。具体来说，该算法不仅强化了有助于正确解决问题的现有推理模式，而且逐渐产生了最初不存在的全新推理模式。这一发现揭示了RL算法的适应性和探索能力，并为模型的学习机制提供了新的见解。

例如，在模型训练的早期阶段，几乎没有对之前的推理步骤进行检查和反思。然而，随着训练的进行，该模型表现出明显的反射和回溯行为，如所示。这一观察为进一步探索RL过程中推理能力的出现提供了线索，我们将其留给未来的研究。

5 结论

在本文中，我们发布了一个完全开源的大规模LLM RL系统，包括算法、代码基础设施和数据集。该系统实现了最先进的大规模LLM RL性能（使用Qwen-32B预训练模型的AIME 50）。我们提出了解耦剪辑和动态采样策略优化（DAPO）算法，并引入了4项关键技术，使RL在长CoT RL场景中具有强大的有效性和高效性。此外，通过开源训练代码和数据集，我们为更广泛的研究界和社会提供了可扩展的强化学习解决方案的实用途径，使所有人都能从这些进步中受益。

Question:

Given that the base ABC of the tetrahedron $S - ABC$ is an equilateral triangle, the projection H of point A on the face SBC is the orthocenter of $\triangle SBC$, the dihedral angle $H - AB - C$ is 30° , and $SA = 2$, find the volume of the tetrahedron. The answer is in the form $\frac{k}{m}$, so give the value of $k + m$.

Response:

Let us consider the given problem: We need to determine ...

...

Next, let S have coordinates (x_0, y_0, z_0) . Since $SA = 2$, the distance formula gives us $\sqrt{(x_0)^2 + (y_0)^2 + (z_0)^2} = 2$, so we can write $x_0^2 + y_0^2 + z_0^2 = 4$. Now, remember that H is the orthogonal projection of

...

However, wait a moment, let's rethink about the dihedral angle involving planes in a more thoughtful geometric way. Consider the plane $\alpha_1 = ABC$, which lies entirely on the xy coordinate plane (as $z = 0$). Let the plane $\alpha_2 = SBC$. The point A projected perpendicularly to plane α_2 lands on H . The line $l = AB$...

...

Table 2 强化学习中反思行为的出现

贡献

项目负责人 Qiying Yu 算法 Qiying 俞、Zheng Zhang、Ruofei Zhu、Yufeng Yu¹、Xiaochen Zuo、Yu Yue¹

Infrastructure*

Tiantian Fan¹、Gaohong Liu¹、Lingjun Liu¹、Xin Liu、Haibin Lin、Zhiqi Lin、Bole Ma、Guangming Sheng、Yuxuan Tong、Qiying Yu、张弛、张莫凡、王章、Hang Zhu、Jinhua Zhu 按字母顺序排列的姓氏数据集 Jiaze Chen、Jiangjie Chen、Chengyi Wang、Hongli Yu^{11,2,4}、Weinan Dai、Yuxuan Song、Xiangpeng Wei¹¹、Qiing Yu¹

*监事

郝 Zhou、Jingjing Liu^{2,4}、Wei Ying Ma^{2,4}、Ya Qin Zhang^{2,4}、Lin Yan、Mu Qiao^{2,42,4}、Yonghui Wu^{2,41,4}、Mingxuan Wang^{1,4} 清华大学字节跳动人工智能产业研究所 (AIR)

附属

¹ 机构香

⁴ 港大学

³ 清华 AIR 与字节跳动种子

² SIA 实验室

致谢

我们感谢杜正银、沈凯、詹天阳、肖震、郑仁杰、李涵、蒋开华以及字节跳动的其他同事对该 DAPO 项目的支持。

References

- [1] OpenAI. Learning to reason with llms, 2024.
- [2] Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. [arXiv preprint arXiv:2501.12948](#), 2025.
- [3] OpenAI. GPT4 technical report. [arXiv preprint arXiv:2303.08774](#), 2023.
- [4] Anthropic. Claude 3.5 sonnet, 2024.
- [5] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in neural information processing systems*, 33:1877–1901, 2020.
- [6] Aakanksha Chowdhery, Sharan Narang, Jacob Devlin, Maarten Bosma, Gaurav Mishra, Adam Roberts, Paul Barham, Hyung Won Chung, Charles Sutton, Sebastian Gehrmann, et al. Palm: Scaling language modeling with pathways. *Journal of Machine Learning Research*, 24(240):1–113, 2023.
- [7] Aixin Liu, Bei Feng, Bing Xue, Bingxuan Wang, Bochao Wu, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, et al. Deepseek-v3 technical report. [arXiv preprint arXiv:2412.19437](#), 2024.
- [8] XAI. Grok 3 beta — the age of reasoning agents, 2024.
- [9] Google DeepMind. Gemini 2.0 flash thinking, 2024.
- [10] Qwen. Qwq-32b: Embracing the power of reinforcement learning, 2024.
- [11] Kimi Team, Angang Du, Bofei Gao, Bowei Xing, Changjiu Jiang, Cheng Chen, Cheng Li, Chenjun Xiao, Chenzhuang Du, Chonghua Liao, et al. Kimi k1. 5: Scaling reinforcement learning with llms. [arXiv preprint arXiv:2501.12599](#), 2025.
- [12] An Yang, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chengyuan Li, Dayiheng Liu, Fei Huang, Haoran Wei, et al. Qwen2. 5 technical report. [arXiv preprint arXiv:2412.15115](#), 2024.
- [13] Zhipeng Chen, Yingqian Min, Beichen Zhang, Jie Chen, Jinhao Jiang, Daixuan Cheng, Wayne Xin Zhao, Zheng Liu, Xu Miao, Yang Lu, et al. An empirical study on eliciting and improving r1-like reasoning models. [arXiv preprint arXiv:2503.04548](#), 2025.
- [14] Jingcheng Hu, Yinmin Zhang, Qi Han, Daxin Jiang, and Heung-Yeung Shum Xiangyu Zhang. Open-reasoner-zero: An open source approach to scaling reinforcement learning on the base model. <https://github.com/Open-Reasoner-Zero/Open-Reasoner-Zero>, 2025.
- [15] Jian Hu. Reinforce++: A simple and efficient approach for aligning large language models. [arXiv preprint arXiv:2501.03262](#), 2025.
- [16] Ganqu Cui, Lifan Yuan, Zefan Wang, Hanbin Wang, Wendi Li, Bingxiang He, Yuchen Fan, Tianyu Yu, Qixin Xu, Weize Chen, et al. Process reinforcement through implicit rewards. [arXiv preprint arXiv:2502.01456](#), 2025.
- [17] Jung Hyun Lee, June Yong Yang, Byeongho Heo, Dongyoon Han, and Kang Min Yoo. Token-supervised value models for enhancing mathematical reasoning capabilities of large language models. [arXiv preprint arXiv:2407.12863](#), 2024.
- [18] Amirhossein Kazemnejad, Milad Aghajohari, Eva Portelance, Alessandro Sordoni, Siva Reddy, Aaron Courville, and Nicolas Le Roux. Vineppo: Unlocking rl potential for llm reasoning through refined credit assignment. [arXiv preprint arXiv:2410.01679](#), 2024.
- [19] Yufeng Yuan, Yu Yue, Ruofei Zhu, Tiantian Fan, and Lin Yan. What’s behind ppo’s collapse in long-cot? value optimization holds the secret. [arXiv preprint arXiv:2503.01491](#), 2025.
- [20] Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. Hybridflow: A flexible and efficient rlhf framework. [arXiv preprint arXiv:2409.19256](#), 2024.
- [21] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. [arXiv preprint arXiv:1707.06347](#), 2017.

- [22] John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation, 2018.
- [23] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul F Christiano, Jan Leike, and Ryan Lowe. Training language models to follow instructions with human feedback. In S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh, editors, *Advances in Neural Information Processing Systems*, volume 35, pages 27730–27744. Curran Associates, Inc., 2022.
- [24] Dario Amodei, Chris Olah, Jacob Steinhardt, Paul Christiano, John Schulman, and Dan Mané. Concrete problems in ai safety, 2016.
- [25] Tom Everitt, Victoria Krakovna, Laurent Orseau, Marcus Hutter, and Shane Legg. Reinforcement learning with a corrupted reward channel, 2017.
- [26] Victoria Krakovna, Jonathan Uesato, Vladimir Mikulik, Matthew Rahtz, Tom Everitt, Ramana Kumar, Zac Kenton, Jan Leike, and Shane Legg. Specification gaming: the flip side of ai ingenuity, 2020.
- [27] Tom Everitt, Marcus Hutter, Ramana Kumar, and Victoria Krakovna. Reward tampering problems and solutions in reinforcement learning: A causal influence diagram perspective, 2021.
- [28] Leo Gao, John Schulman, and Jacob Hilton. Scaling laws for reward model overoptimization, 2022.
- [29] Lilian Weng. Reward hacking in reinforcement learning. lilianweng.github.io, Nov 2024.
- [30] Stanislas Polu and Ilya Sutskever. Generative language modeling for automated theorem proving, 2020.
- [31] Trieu H Trinh, Yuhuai Wu, Quoc V Le, He He, and Thang Luong. Solving olympiad geometry without human demonstrations. *Nature*, 625(7995):476–482, 2024.
- [32] Trieu Trinh and Thang Luong. Alphageometry: An olympiad-level ai system for geometry, 2024.
- [33] AlphaProof and AlphaGeometry Teams. Ai achieves silver-medal standard solving international mathematical olympiad problems, 2024.
- [34] Hung Le, Yue Wang, Akhilesh Deepak Gotmare, Silvio Savarese, and Steven Chu Hong Hoi. Coderl: Mastering code generation through pretrained models and deep reinforcement learning. *Advances in Neural Information Processing Systems*, 35:21314–21328, 2022.
- [35] Noah Shinn, Federico Cassano, Edward Berman, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: Language agents with verbal reinforcement learning, 2023.
- [36] Xinyun Chen, Maxwell Lin, Nathanael Schärli, and Denny Zhou. Teaching large language models to self-debug, 2023.
- [37] Jonas Gehring, Kunhao Zheng, Jade Copet, Vegard Mella, Quentin Carbonneaux, Taco Cohen, and Gabriel Synnaeve. Rlef: Grounding code llms in execution feedback with reinforcement learning, 2025.
- [38] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Mingchuan Zhang, YK Li, Y Wu, and Daya Guo. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- [39] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. In *International Conference on Learning Representations*, 2019.

Appendix

A 数据集转换

这是一个数据转换的示例，我们演示了原始问题、转换后的问题以及转换过程中的模型输出（原始问题以markdown文本的形式呈现，为了可读性而呈现）。

为了确保模型能够高精度地完成这项任务，我们的目标是让它在避免幻觉的同时进行全面的推理。我们通过提供一个鼓励彻底推理的清晰思维框架来实现这一目标。具体来说，我们采用思维链（CoT）推理以及四个定义明确的步骤：提取答案格式，重写问题陈述，解决修改后的问题，并提供一个整数作为最终答案。对于每一步，我们都会提供少量的解决方案或详细的指导方针来指导模型的推理。

通过这种方法，我们观察到，在大多数情况下，LLM可以生成格式和质量都令人满意的重新配方。

原始问题

设 x 和 y 为实数，以 x 确定答案的 x 最小可能值： $11 - 2\sqrt{6}$

转化问题

设 x 和 y 为实数，从 x 而确定的 x 最小可能值。原始答案的形式 $k - m\sqrt{n}$ 为，其中 k ， m 和 n 是整数。请查找的 $k + m + n$ 值。答案：19

模型输出（Markdown文本）

转型思维过程

这个问题的原始答案是一个代数表达式 $11 - 2\sqrt{6}$ 。我们需要将其转换为整数形式。首先，请注意，答案由整数部分和平方根项组成。根据给定的规则，我们用待定系数替换整数和平方根分量。原始问题使用 x 和 y 作为变量，因此我们选择其他字母作为待定系数。我们在表格 $k - m\sqrt{n}$ 中表达答案，并要求学生找到 $k + m + n$ 。

答案格式

$k - m\sqrt{n}$

转化问题

设 x 和 y 为实数，从 x 而确定的 x 最小可能值。原始答案的形式 $k - m\sqrt{n}$ 为，其中 k ， m 和 n 是整数。请查找的 $k + m + n$ 值。

转换问题的答案计算

- 最初的答案是： $11 - 2\sqrt{6}$ 。
- 所需的格式为： $k - m\sqrt{n}$
- 匹配系数： $k = 11$ 、 $m = 2$ 、 $n = 6$ 。
- 最终结果是： $k + m + n = 11 + 2 + 6 = 19$ 。

最终答案

19

B 补充案例

Question:

Among the 900 residents of Aimeville, there are 195 who own a diamond ring, 367 who own a set of golf clubs, and 562 who own a garden spade. In addition, each of the 900 residents owns a bag of candy hearts. There are 437 residents who own exactly two of these things, and 234 residents who own exactly three of these things. Find the number of residents of Aimeville who own all four of these things.

Response:

Step by Step Solution:

1. Let's define the following variables:

Let A be the set of residents who own a diamond ring.

Let B be the set of residents who own a set of golf clubs.

Let C be the set of residents who own a garden spade.

Let D be the set of residents who own a bag of candy hearts. Since all 900 residents own a bag of candy hearts, $|D| = 900$.

Let a_i denote the number of residents who own exactly i out of the 4 items.

Let's use the principle of inclusion-exclusion for the union of 4 sets A, B, C, D .

...

$$a_4 = \frac{-219}{-4} = \frac{219}{4} = 54.75.$$

Since a_4 , the number of people owning all four items, must be a whole number, our current approach needs to be reconsidered in terms of the combinatorial counting of people owning different combinations of the items.

Instead of directly using the inclusion-exclusion principle, we can use a different approach involving the number of people owning combinations of the items A, B, C , and D .

Let x_i be the number of people owning exactly i item among A, B, C (excluding the item D which everyone owns).

Then the total number of people owning exactly k items among the A, B, C , and D can be broken down:

...

Table 3 一个反思行为出现的案例。