

8 MoE环游记：1、从几何意义出发

Feb By 苏剑林 | 2025-02-08 | 51162位读者

前两年福至心灵之下，开了一个“**Transformer升级之路**”系列，陆续分享了主流Transformer架构的一些改进工作和个人思考，得到了部份读者的认可。这篇文章开始，我们沿着同样的风格，介绍当前另一个主流架构MoE (Mixture of Experts)。

MoE的流行自不必多说，近来火出圈的**DeepSeek-V3**便是MoE架构，传言GPT-4也是MoE架构，国内最近出的一些模型也有不少用上了MoE。然而，虽然MoE的研究由来已久，但其应用长时间内都不愠不火，大致上是从去年初的《**Mixtral of Experts**》开始，MoE才逐渐吸引大家的注意力，其显著优点是参数量大，但训练和推理成本都显著低。

但同时MoE也有一些难题，如训练不稳定、负载不均衡、效果不够好等，这也是它早年没有流行起来的主要原因。不过随着这两年关注度的提升，这些问题在很大程度上已经得到解决，我们在接下来的介绍中会逐一谈到这些内容。

问题定义

首先要指出的是，这里会用笔者自己的一种理解思路来介绍MoE，在必要的地方会附上相应的参考文献，但不会对MoE架构进行系统的追根溯源，还请读者见谅。

我们知道，Transformer模型由Attention层和MLP层组成，MoE替换的是模型中MLP层。MLP层又分FFN (FeedForward Network) 和GLU (Gated Linear Unit) 两种，主流的是GLU，但简单起见我们还是以FFN为例

$$\mathbf{y} = f(\mathbf{x}\mathbf{W}^{(A)})\mathbf{W}^{(B)} \quad (1)$$

其中 $\mathbf{x} \in \mathbb{R}^d$ 是输入向量（行向量）， $\mathbf{W}^{(A)} \in \mathbb{R}^{d \times D}$ ， $\mathbf{W}^{(B)} \in \mathbb{R}^{D \times d}$ 是两个参数矩阵， f 是Element-wise的激活函数。设 n 是一个能整除 D 的整数，那么上述可以等价地用分块矩阵写成

$$\mathbf{y} = f\left(\mathbf{x} \begin{bmatrix} \mathbf{W}_1^{(A)} & \mathbf{W}_2^{(A)} & \cdots & \mathbf{W}_n^{(A)} \end{bmatrix}\right) \begin{bmatrix} \mathbf{W}_1^{(B)} \\ \mathbf{W}_2^{(B)} \\ \vdots \\ \mathbf{W}_n^{(B)} \end{bmatrix} = \sum_{i=1}^n \underbrace{f(\mathbf{x}\mathbf{W}_i^{(A)})\mathbf{W}_i^{(B)}}_{\mathbf{v}_i} \quad (2)$$

其中 $\mathbf{W}_i^{(A)} = \mathbf{W}_{[:,(i-1)c:ic]}^{(A)}$ ， $\mathbf{W}_i^{(B)} = \mathbf{W}_{[(i-1)c:ic,:]}^{(B)}$ ， $c = D/n$ ，这里的切片按照Python规则来。由此可见，FFN可以等价表示成 n 个向量 $\mathbf{v}_1, \mathbf{v}_2, \cdots, \mathbf{v}_n$ 之和，每个向量代表了一个小模型 $f(\mathbf{x}\mathbf{W}_i^{(A)})\mathbf{W}_i^{(B)}$ 的输出，每个小模型计算量相同，这些小模型就是MoE中的“Expert”。

MoE提出的问题是：

能否只挑 k 个向量的和来逼近 n 个向量的和呢？这样就可以将计算量降低到 k/n 了。

模长排序

这个问题其实我们在《低秩近似之路（三）：CR》已经探究过，写成数学公式是

$$\operatorname{argmin}_{\lambda_1, \lambda_2, \dots, \lambda_n \in \{0,1\}} \left\| \sum_{i=1}^n \lambda_i \mathbf{v}_i - \sum_{i=1}^n \mathbf{v}_i \right\|^2 \quad \text{s.t.} \quad \sum_{i=1}^n \lambda_i = k \quad (3)$$

记 $\gamma_i = 1 - \lambda_i$ ，那么它又可以写成

$$\operatorname{argmin}_{\gamma_1, \gamma_2, \dots, \gamma_n \in \{0,1\}} \left\| \sum_{i=1}^n \gamma_i \mathbf{v}_i \right\|^2 \quad \text{s.t.} \quad \sum_{i=1}^n \gamma_i = n - k \quad (4)$$

这个问题的精确求解是比较困难的，但有一个简单的近似解：当 $\mathbf{v}_i$ 两两正交时，我们有

$$\left\| \sum_{i=1}^n \gamma_i \mathbf{v}_i \right\|^2 = \sum_{i=1}^n \gamma_i^2 \|\mathbf{v}_i\|^2 = \sum_{i=1}^n \gamma_i \|\mathbf{v}_i\|^2 \quad (5)$$

上式最优解显然就是让模长 $\|\mathbf{v}_i\|$ 最小的 $n - k$ 个 γ_i 等于1，这又等价于说挑出模长最大的 k 个向量来逼近 n 个向量之和。当 $\mathbf{v}_i$ 不满足两两正交的条件时，我们依然用它来作为一个近似解。它的几何意义也很直观，模长越大的向量，在求和过程中越不容易被抵消，从而作用越突出。

此外，在《低秩近似之路（三）：CR》中我们还讨论了一种依概率采样的逼近过程，在方差最小的假设下得到的最优采样概率同样有正比于模长的特点，所以总的来说按向量模长排序是一个简单但不失有效的策略。

MoE初现

现在策略已经有了——“挑模长最大的 k 个向量”——可是细想之下我们会发现它并不实用：要挑模长最大的 k 个向量，就得把所有向量的模长都算出来，这又意味着要把所有的 $\mathbf{v}_i$ 先算出来，可我们的原本目的却是减少 $\mathbf{v}_i$ 的计算量！

为了解决这个矛盾，我们需要重新设计每个Expert模型，使得它的模长可以低成本地计算出来。什么意思呢？首先我们将 $\mathbf{v}_i$ 归一化得到 $\mathbf{e}_i = \mathbf{v}_i / \|\mathbf{v}_i\|$ ，这样每个 $\mathbf{e}_i$ 的模长都相同了。接着我们定义

$$\underbrace{[\rho_1, \rho_2, \dots, \rho_n]}_{\boldsymbol{\rho}} = h(\mathbf{x} \mathbf{W}^{(R)}) \in \mathbb{R}_{\geq 0}^n \quad (6)$$

其中 $\mathbf{W}^{(R)} \in \mathbb{R}^{d \times n}$ 是参数矩阵， $h(\cdot)$ 是一个 $\mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$ 的激活函数，说白了这就是一个 d 维到 n 维的线性变换加激活函数，所以计算量是比较小的，这部分模型在MoE中被称为“Router”。

$\boldsymbol{\rho}$ 的作用是什么呢？预测每个Expert的模长！换言之，我们将 ρ_i 作为第 i 个Expert的模长， $\rho_i \mathbf{e}_i$ 才是完整的Expert，它被分解为两部分：计算量比较小的模长 ρ_i 以及计算量比较大的方向 $\mathbf{e}_i$ 。为了减少计算量，我们先计算出 $\boldsymbol{\rho}$ ，挑出最大的 k 个后才去计算相应的 $\mathbf{e}_i$ ，最后乘上 ρ_i 并求和：

$$\mathbf{y} = \sum_{i \in \operatorname{argtop}_k \boldsymbol{\rho}} \rho_i \mathbf{e}_i \quad (7)$$

这便是MoE模型的基本公式。由于计算中只保留了Top- k 部分，所以它本质上属于一种Sparse模型，而原本的FN或者 $k = n$ 时的模型，通常称为对应的Dense模型。

思路概括

不管是熟悉MoE还是不熟悉MoE的读者，可能都会对上述过程有点陌生，因为这是笔者自己闭门造车的一种MoE理解路线，但因为其几何意义更明确，所以本质上应该是更好理解的。

我们再来整理一下整个思路：

- 1、一个常规的Dense模型FFN，可以等价改写为 n 个Expert向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 之和；
- 2、为了节省计算量，我们试图挑出 k 个向量求和来逼近原本的 n 个向量之和；
- 3、转化为数学问题求解后，我们发现挑选规则是模长最大的 k 个向量；
- 4、直接去算 n 个Expert的模长然后选 k 个实际上是不省计算量的，所以要重新设计Expert；
- 5、将 $\mathbf{v}_i$ 归一化得到 $\mathbf{e}_i$ ，然后用另外的小模型（Router）预测模长 ρ_i ，最终的Expert为 $\rho_i \mathbf{e}_i$ ；
- 6、此时，我们就可以先算全体 ρ_i ，挑出 k 个后才去计算 $\mathbf{e}_i$ ，达到节省计算量的目的。

为何如此

可能有些读者疑问，为什么要做这个看似复杂的过程？原本的MoE不是挺好理解的吗？一般的MoE形式为

$$\mathbf{y} = \sum_{i \in \text{argtop}_k \rho} \rho_i \mathbf{v}_i \quad (8)$$

也就是求和前少了对 $\mathbf{v}_i$ 的归一化，此时 ρ_i 也没有模长的意义，它纯粹是一个用来对Expert排序的打分模型（即Router）。可为什么将 ρ_i 乘到Expert上去就能让Router学会正确排序Expert呢？笔者发现只有《Sparse Backpropagation for MoE Training》对此给出了一个解释，但还是稍欠直观。

而在本文的几何视角下，我们会发现很多问题就“豁然开朗”了。我们将Expert重新参数化为 $\rho_i \mathbf{e}_i$ 后，Dense模型对应于全体 $\rho_i \mathbf{e}_i$ 求和，而MoE对应于 ρ_i 选Top- k 后求和，这是Dense模型的一个有理论保证的逼近。我们没有去考虑Router如何选择Expert，只是每一步都尽可能逼近Dense模型，这可以说是既要大参数、又要小计算量的最佳选择。

现在 ρ_i 的几何意义是模长而不是概率，所以激活函数 $h(\cdot)$ 就没有归一化的要求了，除了Softmax外，像Sigmoid、ReLU都可以考虑使用，也可以考虑我们在《Softmax后传：寻找Top-K的光滑近似》介绍的Top- k 光滑近似。Router使用非归一化的激活函数，有助于避免 $k > 1$ 时Expert之间的恶性竞争，有时候能取得更好的效果。

最后补充一点，我们前面定义 $\mathbf{e}_i = \mathbf{v}_i / \|\mathbf{v}_i\|$ ，目的是让所有 $\mathbf{e}_i$ 模长相同，实际操作中不是一定要L2 Normalize，也可以是其他等价操作，比如gamma参数恒等于1的RMS Norm，它更符合我们的输出习惯。

文章小结

本文从Dense模型的最佳逼近出发来推导和理解MoE，得到了一种特定的MoE形式，它比现有MoE多了一个Normalize步骤，但能让MoE的几何意义更加明显。当然，不管Normalize与否，MoE之路都只是刚刚开始，更多的困难还在路上。

转载到请包括本文地址：<https://spaces.ac.cn/archives/10699>

更详细的转载事宜请参考：《科学空间FAQ》

如果您需要引用本文，请参考：

苏剑林. (Feb. 08, 2025). 《MoE环游记：1、从几何意义出发》[Blog post]. Retrieved from <https://spaces.ac.cn/archives/10699>

```
@online{kexuefm-10699,  
  title={MoE环游记：1、从几何意义出发},  
  author={苏剑林},  
  year={2025},  
  month={Feb},  
  url={\url{https://spaces.ac.cn/archives/10699}},  
}
```