

21 MoE环游记：2、不患寡而患不均

Feb By 苏剑林 | 2025-02-21 | 24784位读者

在上一篇文章《MoE环游记：1、从几何意义出发》中，我们介绍了MoE的一个几何诠释，旨在通过Dense模型的最佳逼近出发来推导和理解MoE。同时在文末我们也说了，给出MoE的计算公式仅仅是开始，训练一个实际有效的MoE模型还有很多细节补，比如本文要讨论的负载均衡（Load Balance）问题。

负载均衡，即“不患寡而患不均”，说白了就是让每个Expert都在干活，并且都在干尽可能一样多的活，避免某些Expert浪费算力。负载均衡既是充分利用训练算力的需求，也是尽可能发挥MoE大参数量潜力的需求。

需求分析

我们知道，MoE的基本形式是

$$\mathbf{y} = \sum_{i \in \text{argtop}_k \boldsymbol{\rho}} \rho_i \mathbf{e}_i \quad (1)$$

对于传统MoE， $\boldsymbol{\rho}$ 是一个概率分布（Router）， $\mathbf{e}_i = \mathbf{v}_i$ ， $\mathbf{v}_i$ 是一个小型FFN（Expert）的输出；而对于我们上一篇推导的几何MoE， $\boldsymbol{\rho}$ 没有归一化的要求，它预测的是Expert的模长，而 $\mathbf{e}_i = \mathbf{v}_i / \|\mathbf{v}_i\|$ 预测的是Expert的方向。

不管哪种格式的MoE，实际表现都差不多，只是理解视角的不同。但要注意，虽然MoE的公式给人的感觉是“每遇到一个Token，就去找相应的Expert来计算”，但实际训练时其实是反过来的：先给每个Expert分配好相应的算力，然后将Token分配（Route）到所属的Expert中并行计算，这也就为什么负责打分的 $\boldsymbol{\rho}$ 被称为Router。

这样一来，如果Expert的分配不均衡，就可能出现如下局面：某些Expert（Dead Expert）几乎一直闲置，浪费算力；某些Expert要处理的Token太多，根本忙不过来，只能Token Drop（即放弃处理部分Token）。从理论上来说，出现Dead Expert意味着MoE没有达到预期的参数量，即花了大参数量的显存，结果只训出来小参数量的效果。

所以，不管是从训练还是性能角度看，我们都希望保证Expert的负载均衡。

辅助损失

促进负载均衡的常规思路是添加与之相关的损失函数，我们通常称之为“Aux Loss（Auxiliary Loss）”，目前主流用的Aux Loss最早可以追溯到2020年的《GShard: Scaling Giant Models with Conditional Computation and Automatic Sharding》。

介绍Aux Loss之前，我们需要先引入一些新概念。首先，我们已经提到对于一般的MoE来说， $\boldsymbol{\rho}$ 未必是概率分布，我们将归一化的 $\boldsymbol{\rho}$ 记为 $\mathbf{p} = [p_1, p_2, \dots, p_n]$ ，以及它Top- k 版为 $\mathbf{f} = [f_1, f_2, \dots, f_n]$ ，其中

$$p_i = \frac{\rho_i}{\sum_{i=1}^n \rho_i}, \quad f_i = \begin{cases} 1/k, & i \in \text{argtop}_k \boldsymbol{\rho} \\ 0, & i \notin \text{argtop}_k \boldsymbol{\rho} \end{cases} \quad (2)$$

接着我们定义 $\mathbf{P} = \mathbb{E}[\mathbf{p}]$ ， $\mathbf{F} = \mathbb{E}[\mathbf{f}]$ ，这里的 $\mathbb{E}$ 是指对所有样本的所有Token做平均。不难看出， $\mathbf{F}$ 就是Expert当前的负载分布，而 $\mathbf{P}$ 则相当于 $\mathbf{F}$ 的一个光滑近似。

有了这些记号，我们就可以写出Aux Loss为：

$$\mathcal{L}_{\text{aux}} = \mathbf{F} \cdot \mathbf{P} = \sum_{i=1}^n F_i P_i \quad (3)$$

一般文献定义Aux Loss会多乘一个 n ，即它们的Aux Loss等于这里的 $n\mathcal{L}_{\text{aux}}$ 。此外，有些大型MoE可能会按设备来算Aux Loss，以达到设备内的均衡，减少设备间的通信，这些就各自发挥了。但也有较新的实验显示，强行局部均衡极有可能影响模型最终效果。

直通估计

不知道大家有没有发现一个奇怪的现象：不管是最早出处、后续文献还是科普文章，总之笔者阅读过的资料中，对Aux Loss的引用都是不加证明的，似乎大家都公认上述Aux Loss能促进均衡是一件显然成立的事情。可真有这么显然易得吗？

反正笔者是没看出来，所以接下来笔者给出式(3)的一种推导思路，由此思路我们还可以自定义其他形式的Aux Loss。首先，定义均匀分布 $\mathbf{Q} = (1/n, 1/n, \dots, 1/n)$ ，刚才我们说了 $\mathbf{F}$ 就是当前负载分布，因此负载均衡等价于 $\mathbf{F} = \mathbf{Q}$ ，那么下式就是一个比较直观的Aux Loss：

$$\mathcal{L}_{\text{aux}} = \frac{1}{2} \|\mathbf{F} - \mathbf{Q}\|^2 = \frac{1}{2} \sum_{i=1}^n (F_i - 1/n)^2 \quad (4)$$

问题是 $\mathbf{F}$ 是由 argtop_k 出来的，这意味着上式并不是一个能直接用的可导目标。怎么解决这个问题呢？答案是STE (Straight-Through Estimator) 技巧，分别设计前向传播和反向传播的函数。具体来说， $\mathbf{F}$ 不可导， $\mathbf{P}$ 作为它的光滑近似是可导的，那么我们在反向传播的时候将 $\mathbf{F}$ 替换成 $\mathbf{P}$ 就行了，即

$$\mathcal{L}_{\text{aux}} = \frac{1}{2} \|\mathbf{P} + \text{sg}[\mathbf{F} - \mathbf{P}] - \mathbf{Q}\|^2 = \frac{1}{2} \sum_{i=1}^n (P_i + \text{sg}[F_i - P_i] - 1/n)^2 \quad (5)$$

其中 $\text{sg}[]$ 是stop gradient算子，特点是保持前向输出不变，但强制梯度为零。这样改动之后， $\mathcal{L}_{\text{aux}}$ 就是一个切实可行的Aux Loss了，我们可以试求一下它的梯度：

$$\begin{aligned} \nabla_{\theta} \mathcal{L}_{\text{aux}} &= \frac{1}{2} \nabla_{\theta} \sum_{i=1}^n (P_i + \text{sg}[F_i - P_i] - 1/n)^2 \\ &= \sum_{i=1}^n (P_i + \text{sg}[F_i - P_i] - 1/n) \nabla_{\theta} (P_i + \text{sg}[F_i - P_i] - 1/n) \\ &= \sum_{i=1}^n (F_i - 1/n) \nabla_{\theta} P_i = \nabla_{\theta} \sum_{i=1}^n (F_i - 1/n) P_i \\ &= \nabla_{\theta} \left(\sum_{i=1}^n F_i P_i \right) \end{aligned} \quad (6)$$

这里 θ 是模型参数。最后的结果表明式(5)的梯度等于式(3)梯度，这意味着用式(3)作为Aux Loss跟式(5)本质是等价的。

一般形式

上述推导实际上提供了构建Aux Loss的一般思路：**首先基于 F 构建符合要求的损失，然后在实现时将 F 替换成 $P + \text{sg}[F - P]$** 。比如，我们知道最大熵也可以将分布推向均衡，因此也可以用熵的相反数来构建Aux Loss：

$$\mathcal{L}_{\text{aux}} = \sum_{i=1}^n (P_i + \text{sg}[F_i - P_i]) \log(P_i + \text{sg}[F_i - P_i]) \quad (7)$$

上式就可以直接用作代码实现，当然如果我们追求简化，也可以类似地求梯度，结果将是

$$\nabla_{\theta} \mathcal{L}_{\text{aux}} = \nabla_{\theta} \sum_{i=1}^n (P_i + \text{sg}[F_i - P_i]) \log(P_i + \text{sg}[F_i - P_i]) = \nabla_{\theta} \sum_{i=1}^n P_i \log F_i \quad (8)$$

两次简化梯度的过程中，我们都用到了如下恒等式

$$\sum_{i=1}^n \nabla_{\theta} P_i = \nabla_{\theta} \sum_{i=1}^n P_i = \nabla_{\theta} 1 = 0 \quad (9)$$

这依赖于 P 是一个概率分布，以及目标分布 Q 是均匀分布的事实。而如果我们不追求简化后的等价结果，而是直接用 $F \rightarrow P + \text{sg}[F - P]$ 形式的Aux Loss，那么可以不受这两个约束。

比如， P 作为 F 光滑近似这一点，我们只用到了“ P_i 大 F_i 通常也大”的性质，所以用非归一化的 $\mathbb{E}[\rho]$ 作为 P 通常也没问题，这一点在一些特殊场景（例如有正有负的 ρ ）可能会比较关键，因为此时无法归一化为概率分布。又比如目标 $\|F - Q\|^2$ ，显然能将 F 推向任意我们想要的、不一定是均匀的目标分布 Q 。

文章小结

本文介绍了MoE的负载均衡问题，并给出了一种构建Aux Loss的一般思路。除了Aux Loss外，促进负载均衡还有一些其他方案，我们下回再谈。

转载到请包括本文地址：<https://spaces.ac.cn/archives/10735>

更详细的转载事宜请参考：《科学空间FAQ》

如果您需要引用本文，请参考：

苏剑林. (Feb. 21, 2025). 《MoE环游记：2、不患寡而患不均》 [Blog post]. Retrieved from <https://spaces.ac.cn/archives/10735>

```
@online{kexuefm-10735,
  title={MoE环游记：2、不患寡而患不均},
  author={苏剑林},
  year={2025},
  month={Feb},
  url={\url{https://spaces.ac.cn/archives/10735}},
}
```