

## 28 Transformer升级之路：6、旋转位置编码的完备性分析

Dec By 苏剑林 | 2022-12-28 | 47920位读者

在去年的文章《Transformer升级之路：2、博采众长的旋转式位置编码》中，笔者提出了旋转位置编码（RoPE），当时的出发点只是觉得用绝对位置来实现相对位置是一件“很好玩的事情”，并没料到其实际效果还相当不错，为大家所接受，不得不说这真是一个意外之喜。后来，在《Transformer升级之路：4、二维位置的旋转式位置编码》中，笔者讨论了二维形式的RoPE，并研究了用矩阵指数表示的RoPE的一般解。

既然有了一般解，那么自然会引出一个问题：我们常用的RoPE，只是一个以二维旋转矩阵为基本单元的分块对角矩阵，如果换成一般解，理论上效果会不会更好呢？本文就来回答这个问题。

### 指数通解 #

在《Transformer升级之路：4、二维位置的旋转式位置编码》中，我们将RoPE抽象地定义为任意满足下式的方阵

$$\mathcal{R}_m^\top \mathcal{R}_n = \mathcal{R}_{n-m} \quad (1)$$

然后，我们探讨了如下矩阵指数形式的解

$$\mathcal{R}_n = \exp n\mathbf{B} \quad (2)$$

这里的矩阵指数，不是像Softmax那样的激活函数式的element-wise运算，而是按照泰勒级数定义的“Matrix Exponential”。根据“Baker–Campbell–Hausdorff公式”，我们有

$$\begin{aligned} \mathcal{R}_m^\top \mathcal{R}_n &= (\exp m\mathbf{B})^\top (\exp n\mathbf{B}) = (\exp m\mathbf{B}^\top) (\exp n\mathbf{B}) \\ &= \exp \left( m\mathbf{B}^\top + n\mathbf{B} + \frac{1}{2}mn [\mathbf{B}^\top, \mathbf{B}] + \dots \right) \end{aligned} \quad (3)$$

这里 $[\mathbf{A}, \mathbf{B}] = \mathbf{AB} - \mathbf{BA}$ ， $\dots$ 省略的都是 $m, n$ 的三次或三次以上的项。按照式(1)，那么上式指数部分应该等于 $(n - m)\mathbf{B}$ ，这就推出

$$\mathbf{B}^\top = -\mathbf{B} \quad (4)$$

即要求 $\mathbf{B}$ 是反对称矩阵。

### 正交通解 #

进一步地，我们有 $(\exp \mathbf{B})^\top (\exp \mathbf{B}) = \exp(\mathbf{B} - \mathbf{B}) = \mathbf{I}$ 和 $\exp n\mathbf{B} = (\exp \mathbf{B})^n$ ，前者说明 $\exp \mathbf{B}$ 是正交矩阵，后者则启示我们这是不是可以推广到任意正交矩阵？不难验证，答案是肯定的，我们有结论：

对于任意正交矩阵 $\mathbf{O}$ ， $\mathcal{R}_n = \mathbf{O}^n$ 是满足式(1)的解。

值得指出的是，在实数域内，并非所有正交矩阵能写成 $\exp \mathbf{B}$ 的形式，所以 $\mathbf{O}^n$ 实际上比矩阵指数形式更宽泛。从《恒等式 $\det(\exp(\mathbf{A})) = \exp(\text{Tr}(\mathbf{A}))$ 赏析》可知 $\det(\exp(\mathbf{A})) = \exp(\text{Tr}(\mathbf{A})) > 0$ ，所以能写成矩阵指数形式的正交矩阵行列式必然大于0（即等于1），事实上这个结果反过来也成立，即行列式等于1的正交矩阵，必然可

以写成 $\exp \mathbf{B}$ 的形式，其中 $\mathbf{B}$ 是反对称矩阵。（参考《Why can any orthogonal matrix be written as  $\mathbf{O}=\mathbf{e}^{\mathbf{A}}$ 》）

。

而对于 $\det(\mathbf{O}) = -1$ 的正交矩阵，我们有 $\mathbf{O} = \mathbf{O}_+ \mathbf{I}_-$ ，其中 $\mathbf{I}_-$ 是对角线元素有一个-1、剩下都是1的对角阵， $\mathbf{O}_+$ 则是 $\det(\mathbf{O}_+) = 1$ 的正交矩阵，它可以写成 $\exp \mathbf{B}$ 的形式，此时 $\mathbf{O}^n = (\mathbf{O}_+ \mathbf{I}_-)^n = \mathbf{I}_-^n \exp n\mathbf{B}$ 。这也就是说，即便对于 $\det(\mathbf{O}) = -1$ 的 $\mathbf{O}^n$ ，也只是 $\exp n\mathbf{B}$ 的简单变换，所以接下来我们主要研究 $\exp n\mathbf{B}$ 形式的解

。

## 完备分析 #

众所周知，我们平时所用的RoPE位置编码，是如下形式的分块对角矩阵：

$$\begin{pmatrix} \cos n\theta_0 & -\sin n\theta_0 & 0 & 0 & \cdots & \cdots & 0 & 0 \\ \sin n\theta_0 & \cos n\theta_0 & 0 & 0 & \cdots & \cdots & 0 & 0 \\ 0 & 0 & \cos n\theta_1 & -\sin n\theta_1 & \cdots & \cdots & 0 & 0 \\ 0 & 0 & \sin n\theta_1 & \cos n\theta_1 & \cdots & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \ddots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \vdots & \ddots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & \cdots & \cos n\theta_{d/2-1} & -\sin n\theta_{d/2-1} \\ 0 & 0 & 0 & 0 & \cdots & \cdots & \sin n\theta_{d/2-1} & \cos n\theta_{d/2-1} \end{pmatrix} \quad (5)$$

它可以简写成

$$\begin{pmatrix} \mathbf{R}_{n\theta_0} & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & \mathbf{R}_{n\theta_1} & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \mathbf{R}_{n\theta_{d/2-1}} \end{pmatrix} = \exp n \begin{pmatrix} \mathbf{J}_{\theta_0} & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & \mathbf{J}_{\theta_1} & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \mathbf{J}_{\theta_{d/2-1}} \end{pmatrix} \quad (6)$$

其中

$$\mathbf{R}_\theta = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}, \quad \mathbf{J}_\theta = \begin{pmatrix} 0 & -\theta \\ \theta & 0 \end{pmatrix} \quad (7)$$

这种选择可以说是最简单的一种，其本质原因可以说是为了降低计算量。那么，所谓完备性问题，就是要回答：如上的分块对角矩阵的特例，相比全参数 $\exp n\mathbf{B}$ ，是否有能力上的缺失？换句话说，如果不考虑计算量，将 $\mathbf{B}$ 替换为一般的反对称矩阵，效果是否可能会有提升？

回答这个问题不困难，事实上，对于任意偶数阶反对称矩阵，它都可以对角化为分块对角矩阵

$$\mathbf{\Lambda} = \begin{pmatrix} \mathbf{J}_{\theta_0} & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & \mathbf{J}_{\theta_1} & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \mathbf{J}_{\theta_{d/2-1}} \end{pmatrix} \quad (8)$$

该结论可以参考Skew-symmetric matrix。也就是说，存在可逆矩阵 $\mathbf{P}$ ，使得 $\mathbf{B} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^{-1}$ ，于是

$$\exp n\mathbf{B} = \exp(n\mathbf{P}\mathbf{\Lambda}\mathbf{P}^{-1}) = \mathbf{P}(\exp n\mathbf{\Lambda})\mathbf{P}^{-1} \quad (9)$$

也就是说，任意的 $\exp n\mathbf{B}$ 与分块对角的 $\exp n\mathbf{\Lambda}$ ，仅仅相差一个相似变换，而我们在Self Attention中应用RoP

E时，是

$$\mathbf{q}^\top (\exp(n-m)\mathbf{B})\mathbf{k} = (\mathbf{P}^\top \mathbf{q})^\top (\exp(n-m)\mathbf{\Lambda})(\mathbf{P}^{-1}\mathbf{k}) \quad (10)$$

由于 $\mathbf{q}, \mathbf{k}$ 一般都是输入 $\mathbf{x}$ 经过某个可学习的线性变换而来， $\mathbf{P}^\top, \mathbf{P}^{-1}$ 原则上都可以吸收到线性变换的训练参数中，因此直接设为 $\mathbf{q}^\top (\exp(n-m)\mathbf{\Lambda})\mathbf{k}$ 理论上不会损失一般性。

所以，对于Self Attention来说，问题的答案是否定的。不过，如果是线性Attention，答案会有少许区别，因为线性Attention的 $\mathbf{q}, \mathbf{k}$ 加了个激活函数：

$$\phi(\mathbf{q})^\top (\exp(n-m)\mathbf{B})\varphi(\mathbf{k}) = (\mathbf{P}^\top \phi(\mathbf{q}))^\top (\exp(n-m)\mathbf{\Lambda})(\mathbf{P}^{-1}\varphi(\mathbf{k})) \quad (11)$$

这就导致了 $\mathbf{P}^\top, \mathbf{P}^{-1}$ 不一定能吸收到线性变换的训练参数中，因此对线性Attention补上两个参数矩阵，是有可能带来提升的。

## 文章小结 #

本文简单分析了RoPE的完备性问题，表明对于Self Attention来说，目前的分块对角型RoPE不会损失一般性。

转载到请包括本文地址：<https://spaces.ac.cn/archives/9403>

更详细的转载事宜请参考：《科学空间FAQ》

如果您需要引用本文，请参考：

苏剑林. (Dec. 28, 2022). 《Transformer升级之路：6、旋转位置编码的完备性分析》[Blog post]. Retrieved from <https://spaces.ac.cn/archives/9403>

```
@online{kexuefm-9403,
  title={Transformer升级之路：6、旋转位置编码的完备性分析},
  author={苏剑林},
  year={2022},
  month={Dec},
  url={\url{https://spaces.ac.cn/archives/9403}},
}
```