

20 《为什么现在的LLM都是Decoder-only的架构?》FAQ

Mar By 苏剑林 | 2023-03-20 | 59975位读者

上周笔者写了《为什么现在的LLM都是Decoder-only的架构?》，总结了一下我在这个问题上的一些实验结论和猜测。果然是热点问题流量大，paperweekly的转发没多久阅读量就破万了，知乎上点赞数也不少。在几个平台上，陆陆续续收到了读者的一些意见或者疑问，总结了其中一些有代表性的问题，做成了本篇FAQ，希望能进一步帮助大家解决疑惑。

回顾

在《为什么现在的LLM都是Decoder-only的架构?》中，笔者对GPT和UniLM两种架构做了对比实验，然后结合以往的研究经历，猜测了如下结论：

- 1、输入部分的注意力改为双向不会带来收益，Encoder-Decoder架构的优势很可能只是源于参数翻倍；
- 2、双向注意力没有带来收益，可能是因为双向注意力的低秩问题导致效果下降。

所以，基于这两点推测，我们得到结论：

在同等参数量、同等推理成本下，Decoder-only架构是最优选择。

相关实验和思考的细节，请读者移步阅读原文，这里就不重复了。

问答

这里对读者的部分疑惑给出自己的答案。

问题1： $n \gg d$ 似乎不成立？

答： n 是序列长度， d 是 head_size 不是 hidden_size，在多头注意力中， $\text{head_size} = \text{hidden_size} / \text{heads}$ ，比如 BERT base 中 $\text{head_size} = 768 / 12 = 64$ ，而预训练长度 n 一般为 512，所以 $n \gg d$ 大致上都是成立的。

问题2： BERT 和初代 GPT 参数量一样，为什么 BERT 在理解任务上更好呢？

答： BERT 和 GPT 不仅架构不一样，预训练任务也不一样，无法公平比较。原文最后笔者已经给出了一个利用 GPT 的思想改进 BERT 的思路，并且初步的实验显示它很可能会优于 BERT，那个实验才是严格控制变量的。

问题3： “双向注意力的低秩问题带来的效果下降”这看起来像一个 bug。现在工业界绝大多数模型都是双向注意力，波及范围也太广了吧？

答： 我们并没有说“双向注意力在任何任务上都非常糟糕”之类的结论，“现在工业界绝大多数模型都是双向注意力”这个现象其实跟原文的结论并不冲突。我们在原文的实验结论是“在生成任务上的 Encoder 引入双向注意力似乎不会带来收益”，结论的条件是很明确的——“在生成任务的 Encoder”。

问题4： 不是吧...decoder模型更适合对话模型而已，在谷歌内部，基于llm的encoder模型，decoder模型和encoder-decoder模型都有，适用场景不同，其他两个在其他任务上效果更好

答： 这个问题的回答跟上一个问题类似，“decoder模型和encoder-decoder模型都有”的现象，跟原文结论不矛盾。我们只是初步推测“在生成任务上的Encoder引入双向注意力似乎不会带来收益”，并没有说Encoder带来的参数翻倍不会带来收益。

问题5： 你的结论跟T5、UL2的结论似乎矛盾？

答： 首先，原文的结论跟UL2的并不矛盾，原文推测“在同等参数量、同等推理成本下，Decoder-only架构是最优选择”，UL2的结论是Encoder-Decoder效果更好，但Encoder-Decoder和Decoder-only不是同等参数量的。其次，原文的结论跟T5中的实验结果（Table 2）确实有些冲突，然而，我对T5的实验结果也存疑：

- 1、该表格中的decoder-only与unilm是否真的做到了严格的控制变量，因为两者相差实在太大了，感觉这个差距是不合理的，即纵然decoder-only可能不如unilm，但差距应该不至于那么大；
- 2、本文中比较的是同样的任务和数据前提下，用unilm和decoder-only分别从零训练，对比训练结果（直接对比预训练的结果，不微调到其他任务上）；而T5论文比较的是各种任务预训练后，再在下游任务微调的结果。两者流程不一样，是否可能产生结果上的差异？

问题6： 最后的实验loss下降更快能说明模型效果更好吗？

答： 在目前笔者训练的步数来看，正反混合注意力表现一直更好，只能猜测后面这个趋势也一直保持，这是目前我能做到的实验上限了。期待有兴趣有条件的读者能进一步实验来肯定或者否定该结论。

问题7： 关于您说的“GPT跟UniLM相比才算是严格控制变量”，我觉得不太准确。Google UL2论文指出，对于 pre-trained language model，模型架构与预训练任务都对模型质量起关键作用。

答： 本文的UniLM和GPT，指的是只有Attention Mask不一致的两个模型架构，在做对比实验的时候，除了Attention Mask不一致外，其他所有细节都是对齐的。

问题8： 会不会还有一个原因，下三角或上三角mask更能够把位置编码的信息处理得更好？

答： 这确实是一个很新颖的观点，我没有从这个角度思考过。但事实上，三角形mask除了带来秩的提升外，确实也带来了位置识别上的优势，它打破了transformer的置换不变性，直接引入了从左往右的序，所以甚至不加位置编码都行。也许两者都是起作用的原因。

小结

本文对上一篇文章部分读者提出的一些疑问做了回答。

转载到请包括本文地址: <https://spaces.ac.cn/archives/9547>

更详细的转载事宜请参考: 《科学空间FAQ》

如果您需要引用本文, 请参考:

苏剑林. (Mar. 20, 2023). 《为什么现在的LLM都是Decoder-only的架构? 》FAQ 》 [Blog post]. Retrieved from <https://spaces.ac.cn/archives/9547>

```
@online{kexuefm-9547,  
  title={《为什么现在的LLM都是Decoder-only的架构? 》FAQ},  
  author={苏剑林},  
  year={2023},  
  month={Mar},  
  url={\url{https://spaces.ac.cn/archives/9547}},  
}
```